

PREDICCIÓN DEL CONSUMO ENERGÉTICO DE UN SISTEMA HVAC Y CARGA TÉRMICA DE UN EDIFICIO DEPENDIENDO DE LAS CONDICIONES EXTERIORES

Edgar Andres Barrera Vega - CC: 1032467347

Maestría en Ingeniería, Facultad de Ingeniería

Universidad de Antioquia

Medellín

20 de noviembre de 2024

Resumen

En este artículo se presenta EL trabajo final para la asignatura de Deep Learning, cuyo objetivo fue utilizar un conjunto de datos descargado de Kaggle sobre el consumo energético de un sistema HVAC (Heating, Ventilation and Air Conditioning) y la carga térmica de un edificio con un sistema centralizado basado en un enfriador de agua (Chiller). Los datos incluyen las variables típicas de un sistema HVAC, tanto del sistema mismo como de las condiciones exteriores. El objetivo del proyecto es predecir el consumo energético del sistema y su eficiencia EER (Energy Efficiency Ratio) en función de las condiciones exteriores.

Contexto de la Aplicación

Un sistema HVAC (Heating, Ventilation, and Air Conditioning, o en español Calefacción, Ventilación y Aire Acondicionado) es una tecnología esencial en edificaciones modernas, que se encarga de controlar la temperatura, la humedad y la calidad del aire dentro de un espacio. El propósito de un sistema HVAC es proporcionar confort térmico y calidad del aire adecuada tanto en edificios residenciales como comerciales. Estos sistemas consumen una parte significativa de la energía total de una edificación, ya que son responsables de mantener las condiciones internas de confort bajo diferentes condiciones climáticas exteriores.

Existen diferentes tipos de sistemas HVAC según el mecanismo que utilizan para generar el enfriamiento, los cuales incluyen sistemas de expansión directa (DX) y sistemas de enfriamiento de agua. En los sistemas de expansión directa, el refrigerante absorbe el calor del aire directamente en las unidades interiores, lo que los hace adecuados para espacios pequeños o medianos. Por otro lado, los sistemas de enfriamiento de agua utilizan un proceso más complejo y son más comunes en edificaciones de gran tamaño, como edificios comerciales, hospitales y grandes oficinas.

En el caso de los sistemas de enfriamiento de agua, el componente principal es el chiller. Un chiller es una máquina que elimina el calor del agua, bajando su temperatura para que pueda ser utilizada para enfriar los espacios del edificio. En un sistema HVAC con enfriamiento de agua, el chiller enfría el agua, la cual es posteriormente distribuida a través de una red de tuberías a las unidades manejadoras de aire (UMAs). Estas unidades, a su vez, hacen circular el aire interior a través de serpentines enfriados por el agua, disminuyendo la temperatura del aire antes de ser distribuido en el edificio. Finalmente, el agua calentada por el proceso de transferencia de calor es devuelta al chiller para ser nuevamente enfriada, completando el ciclo.

Dado su papel preponderante en el consumo energético, la predicción del uso de energía de los sistemas HVAC se vuelve esencial para garantizar la eficiencia energética de una edificación. La capacidad para anticipar el consumo energético permite a los diseñadores y operadores implementar estrategias que optimicen el rendimiento del sistema, reduzcan costos operativos y minimicen el impacto ambiental.

Por ejemplo, al emplear datos históricos y modelos de aprendizaje automático, es posible predecir el consumo energético del sistema en función de diversos factores, como las condiciones climáticas

externas, la ocupación del edificio y la hora del día. Esta información es crucial para ajustar el funcionamiento del sistema HVAC, permitiendo una gestión más eficiente de los recursos energéticos.

La eficiencia de los sistemas HVAC, especialmente los que utilizan chillers para el enfriamiento de agua, puede verse mejorada mediante la implementación de tecnologías de control y automatización. Estas tecnologías permiten adaptar la operación del sistema a las necesidades reales del edificio, minimizando el uso de energía durante períodos de baja demanda y evitando picos de consumo que pueden resultar en altos costos operativos.

Objetivos de Machine Learning

El objetivo de implementar técnicas de Machine Learning es predecir el consumo energético del sistema HVAC basado en un chiller, teniendo en cuenta las condiciones externas. Además, se pretende estimar la eficiencia de este equipo en relación con la energía eléctrica consumida:

1. Carga Térmica en Toneladas de Refrigeración [RT]
2. Eficiencia Energética EER

Como se mencionó, nuestro enfoque incluye la predicción de la eficiencia energética (EER), que se define como la relación entre la capacidad de refrigeración, expresada en unidades inglesas (BTU/h), y el consumo eléctrico, medido en vatios. Asimismo, la carga térmica se expresará en toneladas de refrigeración y dependerá de diversas condiciones externas, tales como:

1. Temperatura exterior
2. Temperatura de Rocío
3. Humedad Relativa
4. Velocidad del Viento

Dataset

Las características de entrada del conjunto de datos incluyen: Marca de tiempo, Tasa de agua helada (L/seg), Temperatura del agua de enfriamiento (C), Carga del edificio (RT), Energía total (kWh), Temperatura (F), Punto de rocío (F), Humedad Relativa, Velocidad del viento (mph), Presión (pulgadas), Hora del día (h) y Día de la semana.

Los conjuntos de datos contienen información relacionada con un edificio comercial ubicado en Singapur, desde el 18/08/2019 a las 00:00 hasta el 01/06/2020 a las 13:00, refinado a 13,561 muestras de datos tras eliminar valores atípicos y datos faltantes, y un tamaño en disco de 746.7 kB.

Métricas de Desempeño

Para esta propuesta de trabajo, utilizaremos el Error Cuadrático Medio Raíz (RMSE, por sus siglas en inglés: Root Mean Square Error) como métrica de desempeño, ya que el objetivo del proyecto es abordar un problema de regresión donde intentaremos predecir dos magnitudes clave: la eficiencia energética del sistema HVAC y la carga térmica del edificio.

En nuestra propuesta de trabajo, al utilizar el RMSE como métrica de desempeño, podremos cuantificar de manera efectiva la precisión de nuestras predicciones sobre la eficiencia energética del sistema HVAC y la carga térmica del edificio. Esto nos permitirá realizar ajustes y mejoras en nuestro modelo, asegurando que el sistema que estamos desarrollando sea capaz de predecir de manera fiable y precisa según los datos de entrada disponibles. En resumen, el RMSE no solo nos ayudará a medir la efectividad de nuestro modelo, sino que también proporcionará una base sólida para la optimización continua del mismo, contribuyendo a un mejor diseño y funcionamiento del sistema HVAC en el edificio.

Notebooks

En este trabajo se describe el proceso realizado en la implementación de un modelo de red neuronal recurrente (RNN) para la predicción del consumo energético en un edificio, centrándose específicamente en la carga térmica y el consumo energético de un sistema de chillers. Para ello, se utilizó un conjunto de herramientas y recursos específicos que permitieron abordar el problema de manera eficiente y reproducible.

Librerías Utilizadas


Se emplearon varias librerías esenciales para el desarrollo y entrenamiento del modelo, entre las cuales destacan:


TensorFlow y Keras: para la construcción y entrenamiento de las redes neuronales recurrentes (RNN), incluyendo capas Dense y SimpleRNN, facilitando la implementación de redes neuronales profundas con capacidades de aprendizaje secuencial. NumPy y Pandas: para la manipulación y análisis de datos, permitiendo la carga, transformación y exploración inicial del conjunto de datos. Matplotlib: para la visualización de los resultados obtenidos durante el proceso de entrenamiento y la evaluación del modelo, facilitando la interpretación de las predicciones y comparaciones con los datos reales. Local.lib: Se hizo uso del repositorio local.lib proporcionado en el entorno de la clase, el cual contiene una serie de funciones personalizadas que optimizan el procesamiento y análisis de datos. Este repositorio fue fundamental para automatizar tareas repetitivas y gestionar eficientemente las operaciones sobre los datos.

Análisis de Datos

El primer paso consistió en un análisis exploratorio detallado de los datos disponibles, almacenados en el conjunto de datos denominado dataset. Este conjunto contenía diversas variables asociadas a la operación de los sistemas térmicos y energéticos del edificio. Se identificaron las columnas relevantes para la predicción del consumo energético del sistema de chillers, tales como la carga térmica del edificio y el consumo energético del chiller. A partir de estas variables, se seleccionaron los datos más pertinentes, limpiándolos de posibles valores atípicos y valores nulos que pudieran afectar el desempeño del modelo.

Con base en los datos procesados, se procedió a la creación de los datasets correspondientes para entrenar los modelos de redes neuronales. Estos datasets fueron generados utilizando las series temporales de la carga térmica y el consumo energético, que son variables interdependientes con un comportamiento secuencial. Para ello, se aplicaron transformaciones y normalizaciones necesarias para asegurar que los datos estuvieran en el formato adecuado para el entrenamiento.





Se realizó un análisis de autocorrelación parcial (PACF) en las variables de carga térmica y consumo energético del chiller para evaluar las dependencias temporales entre los datos. Este análisis permitió identificar que ambas variables presentan una relación significativa hasta dos períodos atrás, lo que indica que los valores actuales de estas variables dependen de los dos valores previos. La autocorrelación parcial ayudó a confirmar que las relaciones temporales más cercanas en el tiempo son las más relevantes para la predicción del consumo energético y la carga térmica, lo cual justificó la utilización de redes neuronales recurrentes para capturar esta dependencia secuencial. Este análisis fue crucial para la correcta selección de las características y la estructura del modelo, garantizando que se aprovecharan adecuadamente las correlaciones temporales en los datos.




Figura 1: Carga Térmica del Sistema HVAC




Figura 2: Consumo Energetico del Sistema HVAC

Implementación de Redes Neuronales Recurrentes

El siguiente paso fue la construcción y entrenamiento de los modelos de redes neuronales recurrentes (RNN), que se utilizaron para modelar la relación temporal entre las variables seleccionadas. Se optó por la implementación de RNNs tanto con capas Dense como utilizando las arquitecturas más complejas de LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Units), las cuales son más adecuadas para el procesamiento de secuencias de datos. La elección de estas arquitecturas respondió a su capacidad para capturar dependencias a largo plazo, lo cual era crucial dada la naturaleza secuencial de los datos.

Utilizando la librería TensorFlow, se configuraron las redes neuronales con las siguientes características:

Capa de entrada: se definieron las características de los datos de entrada, que incluían la carga térmica y el consumo energético del chiller. Capa recurrente: se implemento capas de tipo SimpleRNN, que permiten que el modelo aprenda las dinámicas temporales de las series. Capa densa: se utilizó una capa Dense para la salida, que predice el consumo energético del chiller en función de la carga térmica del edificio. El proceso de entrenamiento se realizó con un conjunto de datos de entrenamiento y validación, utilizando métricas de evaluación como el error cuadrático medio (RMSE) y la precisión para medir el desempeño de los modelos.

Resultados y Visualización

Finalmente, se graficaron los resultados obtenidos durante el entrenamiento de las redes neuronales para analizar la efectividad de los modelos. Se compararon las predicciones del modelo con los valores reales del consumo energético del chiller y la carga térmica, con el fin de visualizar la precisión de los modelos entrenados. Las gráficas incluyeron tanto las curvas de entrenamiento y validación como las predicciones en comparación con los datos reales, permitiendo una evaluación visual clara de la capacidad predictiva del modelo.

En conclusión, la implementación de redes neuronales recurrentes con capas Dense y utilizando TensorFlow permitió abordar de manera efectiva la predicción del consumo energético del chiller a partir de la carga térmica del edificio. La utilización del repositorio local.lib y las herramientas mencionadas optimizó el proceso de análisis y modelado, permitiendo obtener un modelo eficiente y útil para la predicción en el contexto energético.

Los resultados obtenidos con los modelos más sencillos fueron mejores de lo esperado, ya que no se observó overfitting durante el entrenamiento, lo que indica que el modelo no se ajustó en exceso.

a los datos de entrenamiento, manteniendo una buena capacidad de generalización. Las métricas de evaluación fueron satisfactorias, con un RMSE (Root Mean Squared Error) que osciló entre 30 y 39, lo cual es indicativo de un bajo error de predicción. Además, el MAPE (Mean Absolute Percentage Error) se mantuvo entre el 3 por ciento y el 4 por ciento, lo que refleja una precisión alta en las predicciones del modelo, con una variabilidad mínima entre los valores predichos y los valores reales. Estos resultados confirmaron que los modelos sencillos, a pesar de su simplicidad, lograron capturar eficazmente las dinámicas de los datos sin complicaciones adicionales, destacándose por su capacidad predictiva y eficiencia en el proceso de modelado.




Figura 3: Resultado del entrenamiento usando capas SIMPLERNN




Figura 4: Resultado del entrenamiento usando capas DENSE

Referencias

- [1] QUAZI SAMIRA RAHMAN, TSZ HIN JEFFREY LUK, CHUN FAI SIU, HELEN HOI LING KWOK, WEIWEI CHEN y CHIN PANG CHENG, *Energy Consumption in HVAC System and Occupants? Thermal Comfort Optimization Using BIM-Supported Computational Approach*, ZEMCH International Conference, páginas 572, 2021.
- [2] SALEH ABDULAZIZ ALMARZOOQ, ABDULLAH M AL-SHAALAN, HASSAN MH FARH y TAREK KANDIL, *Energy conservation measures and value engineering for small microgrid: new hospital as a case study*, Sustainability, vol. 14, no. 4, páginas 2390, 2022, MDPI.
- [3] JORGE GONZÁLEZ, CARLOS ALBERTO PEREIRA SOARES, MOHAMMAD NAJJAR y ASSED N HADDAD, *BIM and BEM methodologies integration in energy-efficient buildings using experimental design*, Buildings, vol. 11, no. 10, páginas 491, 2021, MDPI.
- [4] CHARU C. AGGARWAL, *Neural Networks and Deep Learning*, Springer, 2018.

- [5] RAUL RAMOS, *Fundamentos de Deep Learning*, Curso de posgrado, Universidad de Antioquia, 2024, Semestre: 2.